

Chapitre 2

Vecteurs aléatoires

I Introduction

Définition 2.1 - *variable aléatoire*

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace de probabilité. On appelle *vecteur aléatoire* sur Ω une application de Ω dans $\mathbb{R}^n$. Pour $n = 1$, on parle de *variable aléatoire*.

Remarque 2.2 - *notation associée*

Pour $A \in \mathbb{R}^n$, on notera $\{X \in A\}$ l'évènement :

$$\{\omega \in \Omega, X(\omega) \in A\}$$

Définition 2.3 - *vecteur aléatoire discret*

Soit $(\Omega, \mathcal{T}, \mathbb{P})$ un espace de probabilité. Un vecteur aléatoire X sur Ω est dit *discret* s'il existe $F \subset \mathbb{R}^n$ au plus dénombrable tel que :

$$\mathbb{P}(\{X \in F\}) = 1$$

Nous émettrons dans le cadre du cours l'hypothèse suivante.

Remarque 2.4 - *en lien avec la définition*

Si X est un vecteur aléatoire sur $(\Omega, \mathcal{T}, \mathbb{P})$, pour tout ouvert A de $\mathbb{R}^n$:

$$\{\omega \in \Omega, X(\omega) \in A\} = \{X \in A\} \in \mathcal{T}$$

Définition 2.5 - vecteur aléatoire à densité

X est un vecteur aléatoire définie sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F s'il existe $p : F \rightarrow \mathbb{R}_+$ qui vérifie pour tout A ouvert de F :

$$\mathbb{P}(\{X \in A\}) = \int_A p(x) \, dx$$

Remarque 2.6 - à ce propos

Pour $A = F$, la probabilité précédemment évoquée vaut :

$$\mathbb{P}(\{X \in F\}) = 1$$

II Lois usuelles

Définition 2.7 - loi d'une variable aléatoire

La loi d'une variable aléatoire discrète X à valeurs dans F (i.e. $\mathbb{P}(\{X \in F\}) = 1$) est entièrement définie par la famille de réels positifs :

$$\left(\mathbb{P}(\{X = x\}) \right)_{x \in F}$$

de somme 1.

Exemple 2.8 - loi de Bernoulli

Pour une loi de Bernoulli :

- $F = \{0, 1\}$
- $\mathbb{P}(\{X = 1\}) = p$ et $\mathbb{P}(\{X = 0\}) = 1 - p$

Une telle variable aléatoire mesure la probabilité de succès d'une épreuve de Bernoulli (succès de probabilité p , échec de probabilité $1 - p$).

Exemple 2.9 - loi binomiale

Pour une loi binomiale :

- $F = \llbracket 0, n \rrbracket$ où $n \in \mathbb{N}^*$
- $\forall k \in \llbracket 0, n \rrbracket, \mathbb{P}(\{X = k\}) = \binom{n}{k} p^k (1-p)^{n-k}$

Une telle variable aléatoire mesure le nombre de succès au terme de la répétition indépendante de n épreuves de Bernoulli du même paramètre p .

Exemple 2.10 - loi géométrique

Pour une loi géométrique :

- $F = \mathbb{N}^*$.
- $\forall k \in \mathbb{N}^*, \mathbb{P}(\{X = k\}) = p(1-p)^{k-1}$

En numérotant à partir de 1 une suite d'épreuves de Bernoulli répétées indépendamment et indéfiniment, une telle variable aléatoire mesure l'indice du premier succès.

Exemple 2.11 - loi de Poisson

Pour une loi de Poisson :

- $F = \mathbb{N}$
- $\forall k \in \mathbb{N}, \mathbb{P}(\{X = k\}) = \frac{\lambda^k}{k!} e^{-\lambda}$

Une loi de Poisson a des intérêts multiples, comme celui d'approximer sous certaines conditions une loi binomiale.

Remarque 2.12 - sur ces lois

On retrouve par dénombrement l'expression de telles lois. Par exemple dans le cas de la loi géométrique, $\{X = k\}$ correspond à l'évènement "La k -ème épreuve est la première à réussir.". Cela revient à avoir vu échouer les $k - 1$ épreuves précédentes :

$$\mathbb{P}(\{X = k\}) = p(1-p)^{k-1}$$

III Lois marginales

Proposition 2.13 - *formule des lois marginales*

Soit X et Y deux vecteurs aléatoires discrètes sur $(\Omega, \mathcal{T}, \mathbb{P})$, respectivement à valeurs dans F et G . On a :

$$1. \forall x \in F, \mathbb{P}(\{X = x\}) = \sum_{g \in G} \mathbb{P}(\{Y = g\})$$

$$2. \forall g \in G, \mathbb{P}(\{Y = g\}) = \sum_{x \in F} \mathbb{P}(\{X = x\})$$

Remarque 2.14 - *démonstration*

On doit ceci à la formule des probabilités totales appliquée aux systèmes complets d'évènements $(Y = g)_{g \in G}$ et $(X = x)_{x \in F}$.

IV Variables aléatoires à densité

Pour une *variable aléatoire à densité*, on dira que la densité caractérise la loi de cette variable aléatoire :

Définition 2.15 - *variable aléatoire à densité*

Soit X est une variable aléatoire sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F . X est qualifiée de *variable aléatoire à densité* s'il existe $p : F \rightarrow [0; 1]$, dite *densité de probabilité*, vérifiant pour toute partie A de F :

$$\mathbb{P}(\{X \in A\}) = \int_A p(t) dt$$

Remarque 2.16 - *sur cette définition*

La donnée de X est alors entièrement caractérisée par sa densité de probabilité p .

Exemple 2.17 - loi de densité uniforme

Pour une loi uniforme de paramètres $a < b$ dans $\mathbb{R}$:

- $F = [a; b]$
- $\forall x \in [a; b], \mathbb{P}(\{X = x\}) = \frac{\mathbb{1}_{[a; b]}(x)}{b - a}$

La fonction **rand** en C suit une loi uniforme sur $[0; 1]$.

Exemple 2.18 - loi de densité gaussienne

Pour une loi gaussienne de paramètres $\mu \in \mathbb{R}$ et $\sigma > 0$:

- $F = \mathbb{R}$
- $\forall x \in [a; b], p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right)$

Exemple 2.19 - loi de densité exponentielle

Pour une loi exponentielle de paramètre $\lambda > 0$:

- $F = \mathbb{R}$
- $\forall x \in \mathbb{R}, p(x) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$

Proposition 2.20 - formule des lois marginales à densité

Soit (X, Y) un couple de variables aléatoires à densité sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans $F \times G$. On note $p_{(X,Y)}$ la densité de probabilité du couple (X, Y) .

Alors p_X et p_Y vérifient :

1. $\forall x \in F, p_X(x) = \int_{\mathbb{R}} p_{(X,Y)}(x, y) \, dy$
2. $\forall y \in G, p_Y(y) = \int_{\mathbb{R}} p_{(X,Y)}(x, y) \, dx$

Démonstration

On montre le premier résultat. Montrons que :

$$\forall x \in \mathbb{R}, p_X(x) = \int_{\mathbb{R}} p_{(X,Y)}(x,y) dy$$

Ce qui revient par définition à montrer que :

$$\forall A \subset F, \mathbb{P}(\{X \in A\}) = \int_A \underbrace{\int_{\mathbb{R}} p_{(X,Y)}(x,y) dy}_{:=p_X(x)} dx$$

Soit $A \subset F$. On a :

$$\begin{aligned} \mathbb{P}(X \in A) &= \mathbb{P}((X,Y) \in A \times G) \\ &= \int_{A \times G} p_{(X,Y)}(x,y) d(x,y) \\ &= \int_A \left(\int_G p_{(X,Y)}(x,y) dy \right) dx \end{aligned}$$

D'où le résultat.

V Espérance d'une variable aléatoire

V.1 Variable aléatoire discrète

Définition 2.21 - famille sommable de réels positifs

On dit qu'une famille $(u_i)_{i \in I}$ de nombres réels positifs est sommable lorsqu'il existe $M \geq 0$ tel que, pour toute partie finie $J \subset I$, on ait $\sum_{j \in J} u_j \leq M$. On définit alors la somme de la famille par :

$$\sum_{i \in I} u_i = \sup_{\substack{J \subset I \\ J \text{ finie}}} \sum_{j \in J} u_j$$

Définition 2.22 - *espérance d'une variable aléatoire discrète*

Soit X une variable aléatoire discrète à valeurs dans $F \subset \mathbb{R}$. X est dite *sommable* si elle admet un moment d'ordre 1 *i.e.* si la famille $\left(x\mathbb{P}(\{X = x\})\right)_{x \in F}$ est sommable. On notera alors $\mathbb{E}(X)$ son espérance définie ainsi :

$$\mathbb{E}(X) = \sum_{x \in F} x\mathbb{P}(\{X = x\})$$

Exemple 2.23 - *espérance d'une fonction indicatrice*

Si A est un évènement de Ω , alors $\mathbb{1}_A : \Omega \rightarrow \{0, 1\}$ est une variable aléatoire sommable (car $\mathbb{1}_A(\Omega)$ est fini). Puis :

$$\mathbb{E}(\mathbb{1}_A) = \mathbb{P}(A)$$

Théorème 2.24 - *formule de transfert pour une variable aléatoire discrète*

Soit X une variable aléatoire discrète sommable à valeurs dans $F \subset \mathbb{R}$ et $g : F \rightarrow G$. Alors $g(X)$ est également une variable aléatoire sommable et :

$$\mathbb{E}(g(X)) = \sum_{x \in F} g(x)\mathbb{P}(\{X = x\})$$

V.2 variable aléatoire à densité

Définition 2.25 - *intégrabilité d'une variable aléatoire à densité*

Soit X une variable aléatoire à densité à valeurs dans F un espace vectoriel de dimension n . On dit de X qu'elle est *intégrable* si l'intégrale :

$$\int_F \|x\| p(x) \, dx$$

converge. Le cas échéant on dit que X admet une espérance $\mathbb{E}(X)$ vérifiant :

$$\mathbb{E}(X) = \underbrace{\int_F \underbrace{x}_{\in F} \underbrace{p(x)}_{\in \mathbb{R}_+} \, dx}_{\in F}$$

Remarque 2.26 - sur cette définition

Il est commun d'avoir $F = \mathbb{R}$ muni de la valeur absolue classique ou $F = \mathbb{R}^n$ peu importe la norme (cf. dimension finie).

V.3 exemples

Exemple 2.27 - espérance d'une loi de Bernoulli

Si X suit une loi de Bernoulli de paramètre $p \in [0; 1]$, alors $X(\Omega) = \{0, 1\}$ est fini, X est donc sommable et :

$$\begin{aligned}\mathbb{E}(X) &= 0 \times (1 - p) + 1 \times p \\ &= p\end{aligned}$$

Exemple 2.28 - espérance d'une loi binomiale

Si X suit une loi binomiale de paramètres $n \in \mathbb{N}^*$ et $p \in [0; 1]$, alors $X(\Omega) = \llbracket 0, n \rrbracket$ est fini, X est donc sommable et :

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} && \text{premier terme nul} \\ &= \sum_{k=1}^n \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k} \\ &= np \sum_{k=1}^n \frac{(n-1)!}{(k-1)!(n-k)!} p^{k-1} (1-p)^{n-k} \\ &= np \sum_{j=0}^{n-1} \frac{(n-1)!}{j!(n-j-1)!} p^j (1-p)^{n-1-j} && \text{changement d'indice} \\ &= np \left(p + (1-p) \right)^{n-1} && \text{formule du binôme de Newton} \\ &= np\end{aligned}$$

d'où le résultat.

Exemple 2.29 - *espérance d'une loi de Poisson*

Si X suit une loi de Poisson de paramètres $n \in \mathbb{N}^*$ et $p \in [0; 1]$, alors $X(\Omega) = \mathbb{N}$ est dénombrable, X est donc sommable seulement si la quantité suivante admet une limite finie quand N tend vers $+\infty$:

$$\begin{aligned}\sum_{k=1}^N k \frac{\lambda^k}{k!} e^{-\lambda} &= \sum_{k=1}^N \frac{\lambda^k}{(k-1)!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^N \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \sum_{j=0}^{N-1} \frac{\lambda^j}{j!} \\ &\xrightarrow{N \rightarrow +\infty} \lambda e^{-\lambda} e^{\lambda} = \lambda\end{aligned}$$

X est donc effectivement sommable, et son espérance vaut :

$$\mathbb{E}(X) = \lambda$$

Exemple 2.30 - *espérance d'une loi géométrique*

Si X suit une loi de géométrie de paramètre $p \in]0; 1[$ (on évite les cas pathologiques), alors $X(\Omega) = \mathbb{N}$ est dénombrable, X est donc sommable seulement si la quantité suivante admet une limite finie quand N tend vers $+\infty$:

$$\sum_{k=1}^N kp(1-p)^{k-1} = p \sum_{k=1}^N k(1-p)^{k-1}$$

Ceci implique la dérivée d'une somme géométrique de raison $(1-p)$, valant :

$$\sum_{k=0}^{+\infty} (1-p)^k = \frac{1}{1-(1-p)} = \frac{1}{p}$$

Par dérivation terme à terme on a bien sommabilité de X , et on trouve :

$$\mathbb{E}(X) = p \sum_{k=1}^{+\infty} k(1-p)^{k-1} = p \frac{1}{p^2} = \frac{1}{p}$$

Exemple 2.31 - *espérance d'une loi à densité exponentielle*

Si X suit une loi exponentielle de paramètre $\lambda > 0$, alors $X(\Omega) = \mathbb{R}_+$ puis :

$$\begin{aligned} f : \mathbb{R}_+ &\longrightarrow \mathbb{R} \\ x &\longmapsto x\lambda e^{-\lambda x} \end{aligned}$$

est continue par morceaux, avec par croissances comparées :

$$\lim_{x \rightarrow \infty} x^2 f(x) = 0$$

donc :

$$f(x) \underset{x \rightarrow \infty}{=} o\left(\frac{1}{x^2}\right)$$

et X est intégrable par comparaison avec une fonction de référence. Son espérance vaut alors :

$$\begin{aligned} \mathbb{E}(X) &= \int_0^{+\infty} x\lambda e^{-\lambda x} \, dx \\ &= \left[-xe^{-\lambda x}\right]_0^{+\infty} + \int_0^{+\infty} e^{-\lambda x} \, dx && \text{intégration par parties} \\ &= 0 + \left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^{+\infty} \\ &= \frac{1}{\lambda} \end{aligned}$$

d'où le résultat.

Exemple 2.32 - espérance d'une loi à densité gaussienne

Si X suit une loi gaussienne de paramètres $\mu \in \mathbb{R}$ et $\sigma > 0$, alors $X(\Omega) = \mathbb{R}$ puis :

$$f : \mathbb{R} \longrightarrow \mathbb{R}$$
$$x \longmapsto x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

est continue par morceaux, avec par croissances comparées :

$$\lim_{x \rightarrow \infty} x^2 f(x) = 0$$

donc :

$$f(x) \underset{x \rightarrow \infty}{=} o\left(\frac{1}{x^2}\right)$$

et X est intégrable par comparaison avec une fonction de référence. Son espérance vaut alors :

$$\begin{aligned}\mathbb{E}(X) &= \int_{-\infty}^{+\infty} x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx \\ &= \int_{-\infty}^{+\infty} (\sigma t + \mu) \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) \sigma dt \quad \text{changement de variable } t = \frac{x-\mu}{\sigma} \\ &= \int_{-\infty}^{+\infty} t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt + \mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt \\ &= 0 + \mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt \quad \text{la première intégrale est nulle par imparité} \\ &= \mu \quad \text{la seconde intégrale vaut 1 (on le montre tout de suite après)}\end{aligned}$$

Enfin montrons que $I = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt = 1$. On a :

$$\begin{aligned}I^2 &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \exp\left(-\frac{1}{2}(x^2 + y^2)\right) dx dy \quad \text{Fubini pour intégrales} \\ &= \frac{1}{2\pi} \int_0^{2\pi} \int_0^{+\infty} r e^{-\frac{1}{2}r^2} dr d\theta \quad \text{changement de variable en coordonnées polaires} \\ &= \frac{1}{2\pi} \times 2\pi \times \left[-e^{-\frac{1}{2}r^2}\right]_0^{+\infty} \\ &= 1\end{aligned}$$

d'où $I = 1$ puis $\mathbb{E}(X) = \mu$.

Remarque 2.33 - sur la démonstration précédente

En passant en coordonnées polaires, on a utilisé le fait que :

$$d(x, y) = r dr d\theta$$

Ceci est une application du théorème de changement de variable en dimension quelconque :

$$\int_{\varphi(U)} f(x) dx = \int_U f(\varphi(x)) \left| \det \left(J_{\varphi}(x) \right) \right| dx$$

où ici :

$$\begin{aligned} \varphi : U = \mathbb{R}_+ \times [0; 2\pi[&\longrightarrow \mathbb{R}^2 \\ (r, \theta) &\longmapsto (r \cos(\theta), r \sin(\theta)) \end{aligned}$$

est un $\mathcal{C}^1$ -difféomorphisme, de jacobien $\det \left(J_{\varphi}(r, \theta) \right)$ en (r, θ) valant r , d'où le résultat.

VI Indépendance de variables aléatoires

Définition 2.34 - indépendance de variables aléatoires

Soit X et Y une famille de variables aléatoires sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F et G respectivement. On dit que X et Y sont *indépendantes* si pour tous $x \in F$ et $y \in G$:

$$\mathbb{P}(\{(X, Y) = (x, y)\}) = \mathbb{P}(\{X = x\})\mathbb{P}(\{Y = y\})$$

Théorème 2.35 - caractérisation de l'indépendance de variables aléatoires

Soit X et Y une famille de variables aléatoires sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F et G respectivement. Les assertions suivantes sont équivalentes :

1. X et Y sont indépendantes.
2. Pour toutes fonctions f et g bornées de F et G respectivement dans $\mathbb{R}$:

$$\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y))$$

Remarque 2.36 - sur ce théorème

Ce théorème sert en particulier dans son sens direct.

Proposition 2.37 - caractérisation de l'indépendance de variables aléatoires à densité

Soit $X_1, \dots, X_n$ des variables aléatoires de densités respectives $p_1, \dots, p_n$. Les X_i sont mutuellement indépendantes si et seulement si $(X_1, \dots, X_n)$ est une variable aléatoire à densité de densité de probabilité :

$$p : (x_1, \dots, x_n) \mapsto \prod_{i=1}^n p_i(x_i)$$

VII Propriétés de l'espérance

Théorème 2.38 - linéarité de l'espérance

Soit X et Y deux variables aléatoires discrètes sommables (resp. intégrables) sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F . Alors pour tous $(\alpha, \beta) \in \mathbb{R}^2$, $\alpha X + \beta Y$ est une variable aléatoire discrète sommable (resp. intégrable) et :

$$\mathbb{E}(\alpha X + \beta Y) = \alpha \mathbb{E}(X) + \beta \mathbb{E}(Y)$$

Théorème 2.39 - croissance de l'espérance

Soit X et Y deux variables aléatoires réelles discrètes sommables (resp. intégrables) sur $(\Omega, \mathcal{T}, \mathbb{P})$. Si $X \leq Y$ presque sûrement, alors :

$$\mathbb{E}(X) \leq \mathbb{E}(Y)$$

Théorème 2.40 - de comparaison d'espérances

Soit X et Y deux variables aléatoires sur $(\Omega, \mathcal{T}, \mathbb{P})$ à valeurs dans F telles que :

- Y est sommable (resp. intégrable)
- $\|X\|_F \leq \|Y\|_F$ presque sûrement.

Alors X est sommable.

VII.1 Des inégalités

Proposition 2.41 - *inégalité de Markov*

Soit X une variable aléatoire réelle positive sommable (resp. intégrable) sur $(\Omega, \mathcal{T}, \mathbb{P})$. Alors :

$$\forall a > 0, \mathbb{P}(\{X \geq a\}) \leq \frac{\mathbb{E}(X)}{a}$$

Démonstration

On a l'inégalité :

$$a\mathbb{1}_{Z \geq a} \leq Z\mathbb{1}_{Z \geq a} \leq Z$$

Par croissance et linéarité de l'espérance :

$$a\mathbb{P}(\{\mathbb{1}_Z\}) \leq \mathbb{E}(Z)$$

Ainsi on a le résultat :

$$\mathbb{P}(Z \geq a) \leq \frac{\mathbb{E}(Z)}{a}$$

Remarque 2.42 - *importante ici*

Si $F \neq \mathbb{R}$ il n'y a qu'à considérer la variable aléatoire $\|X\|_F$, bien à valeurs dans $\mathbb{R}_+$ et lui appliquer le résultat. Cette astuce est utile dans tous les énoncés suivants de la section.

Proposition 2.43 - *inégalité de Bienaymé-Tchebychev*

Soit X une variable aléatoire réelle sommable sur $(\Omega, \mathcal{T}, \mathbb{P})$ admettant une variance finie (ou si X^2 est sommable). Alors :

$$\forall \varepsilon > 0, \mathbb{P}(\{|X - \mathbb{E}(X)| \geq \varepsilon\}) \leq \frac{\mathbb{V}(X)}{\varepsilon^2}$$

Démonstration

On applique l'inégalité de Markov à la variable aléatoire $(X - \mathbb{E}(X))^2$ qui est positive et sommable. On a :

$$\mathbb{P}(\{|X - \mathbb{E}(X)| \geq \varepsilon\}) = \mathbb{P}(\{(X - \mathbb{E}(X))^2 \geq \varepsilon^2\}) \leq \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\varepsilon^2} = \frac{\mathbb{V}(X)}{\varepsilon^2}$$

Proposition 2.44 - *inégalité de Cauchy-Schwarz*

Soit X et Y deux variables aléatoires réelles sommables sur $(\Omega, \mathcal{T}, \mathbb{P})$ telles que XY est sommable. Alors :

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2)}\sqrt{\mathbb{E}(Y^2)}$$

Remarque 2.45 - *cas particulier*

Pour X réelle positive quelconque et $Y = \bar{1}$:

$$\mathbb{E}(X) \leq \sqrt{\mathbb{E}(X^2)}$$

Démonstration

On considère pour tout $t \in \mathbb{R}$ la variable aléatoire :

$$Z_t = X + tY$$

qui est sommable par linéarité. Par croissance de l'espérance :

$$0 \leq \mathbb{E}(Z_t^2) = \mathbb{E}(X^2) + 2t\mathbb{E}(XY) + t^2\mathbb{E}(Y^2)$$

Le polynôme en t de second degré $\mathbb{E}(Y^2)t^2 + 2\mathbb{E}(XY)t + \mathbb{E}(X^2)$ est donc à discriminant négatif ou nul :

$$4\mathbb{E}(XY)^2 - 4\mathbb{E}(Y^2)\mathbb{E}(X^2) \leq 0$$

En effet, si le discriminant était strictement positif, le polynôme s'annulerait en deux points distincts, et serait négatif entre ces deux points. Or on a positivité du polynôme pour tout t .

Le résultat découle de cette dernière égalité.

Remarque 2.46 - *condition suffisante pour que XY soit sommable*

Si X et Y sont deux variables aléatoires réelles sommables telles que X^2 et Y^2 sont sommables, alors XY est sommable par inégalité de Young :

$$|XY| \leq \frac{X^2}{2} + \frac{Y^2}{2}$$

Cette dernière inégalité se démontre en sachant que $(X - Y)^2 \geq 0$.

VIII Variance et covariance

Définition 2.47 - variance d'une variable aléatoire

Soit X une variable aléatoire réelle sommable sur $(\Omega, \mathcal{T}, \mathbb{P})$. On dit que X admet *une variance* si X^2 est sommable. Dans ce cas on note $\mathbb{V}(X)$ la variance de X définie par :

$$\mathbb{V}(X) = \mathbb{E}\left((X - \mathbb{E}(X))^2\right)$$

Proposition 2.48 - formule de König-Huygens

Soit X une variable aléatoire réelle sommable sur $(\Omega, \mathcal{T}, \mathbb{P})$. Si X admet une variance, alors :

$$\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

Démonstration

On développe :

$$\begin{aligned}\mathbb{V}(X) &= \mathbb{E}\left((X - \mathbb{E}(X))^2\right) \\ &= \mathbb{E}(X^2) - 2\mathbb{E}(X)\mathbb{E}(X) + \mathbb{E}(X)^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2\end{aligned}$$

Définition 2.49 - covariance de deux variables aléatoires

Soit X et Y deux variables aléatoires réelles sommables sur $(\Omega, \mathcal{T}, \mathbb{P})$ telles que XY est sommable. On appelle *covariance de X et Y* la quantité :

$$\text{Cov}(X, Y) = \mathbb{E}\left((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))\right)$$

En développant, on trouve :

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Le résultat est bien analogue à la formule de König-Huygens.

Proposition 2.50 - variance de la somme de deux variables aléatoires

Soit X et Y deux variables aléatoires réelles sommables sur $(\Omega, \mathcal{T}, \mathbb{P})$ telles que X^2 et Y^2 sont sommables. On a :

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + \text{Cov}(X, Y)$$

Si X et Y sont indépendantes, alors :

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y)$$

Démonstration

On a :

$$\begin{aligned}\mathbb{V}(X + Y) &= \mathbb{E}\left((X + Y)^2\right) - \mathbb{E}(X + Y)^2 \\ &= \mathbb{E}(X^2) + 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - \left(\mathbb{E}(X) + \mathbb{E}(Y)\right)^2 \\ &= \mathbb{E}(X^2) + 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - \left(\mathbb{E}(X)^2 + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y)^2\right) \\ &= \underbrace{\mathbb{E}(X^2) - \mathbb{E}(X)^2}_{=\mathbb{V}(X)} + \underbrace{\mathbb{E}(Y^2) - \mathbb{E}(Y)^2}_{=\mathbb{V}(Y)} + 2 \underbrace{\left(\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)\right)}_{=\text{Cov}(X,Y)}\end{aligned}$$

Puis si X et Y sont indépendantes, $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$ donc $\text{Cov}(X, Y) = 0$. D'où les résultats.

IX Outils pour le calcul de lois de variables aléatoires

IX.1 fonction génératrice des moments

Inutile mais je pose ça là.

Définition 2.51 - moment d'une variable aléatoire

Soit X une variable aléatoire à valeurs dans F sur $(\Omega, \mathcal{T}, \mathbb{P})$. On dit que X admet un *moment d'ordre n* si $\|X^n\|_F$ est sommable. Dans ce cas on note $\mathbb{E}(X^n)$ le moment d'ordre n de X . En particulier :

- être sommable revient à admettre un moment d'ordre 1
- admettre une variance revient à admettre un moment d'ordre 2.

Définition 2.52 - fonction génératrice pour une VARD

Soit X une variable aléatoire réelle discrète admettant des moments d'ordre n pour tout $n \in \mathbb{N}$. On appelle *fonction génératrice de X* la fonction :

$$\begin{aligned} G_X : \mathbb{R} &\longrightarrow \mathbb{R} \\ t &\longmapsto \mathbb{E}(X^t) \end{aligned}$$

Ainsi car X est discrète :

$$G_X(t) = \sum_{x \in X(\omega)} \mathbb{P}(\{X = x\}) t^x$$

Exemple 2.53 - fonction génératrice d'une loi de Bernoulli

Si X suit une loi de Bernoulli de paramètre $p \in [0; 1]$, alors :

$$G_X(t) = (1 - p) + pt$$

Exemple 2.54 - fonction génératrice d'une loi binomiale

Si X suit une loi binomiale de paramètres $n \in \mathbb{N}^*$ et $p \in [0; 1]$, alors :

$$G_X(t) = (1 - p + pt)^n$$

Questions de cours et remarques

Questions de cours

1. lois discrètes usuelles (de Bernoulli, binomiale, géométrique, de Poisson)
2. lois de densité usuelles
3. inégalité de Markov
4. inégalité de Bienaymé-Tchebychev
5. covariance de la somme de variables aléatoires (et sa démonstration)

Remarques

- Les énoncés sont à énoncer rigoureusement, en toute connaissance des hypothèses associées.