

## Chapitre 2

# Vecteurs aléatoires

### I Introduction

**Définition 2.1** - *variable aléatoire*

Soit  $(\Omega, \mathcal{T}, \mathbb{P})$  un espace de probabilité. On appelle *vecteur aléatoire* sur  $\Omega$  une application de  $\Omega$  dans  $\mathbb{R}^n$ . Pour  $n = 1$ , on parle de *variable aléatoire*.

**Remarque 2.2** - *notation associée*

Pour  $A \in \mathbb{R}^n$ , on notera  $\{X \in A\}$  l'évènement :

$$\{\omega \in \Omega, X(\omega) \in A\}$$

**Définition 2.3** - *vecteur aléatoire discret*

Soit  $(\Omega, \mathcal{T}, \mathbb{P})$  un espace de probabilité. Un vecteur aléatoire  $X$  sur  $\Omega$  est dit *discret* s'il existe  $F \subset \mathbb{R}^n$  au plus dénombrable tel que :

$$\mathbb{P}(\{X \in F\}) = 1$$

Nous émettrons dans le cadre du cours l'hypothèse suivante.

**Remarque 2.4** - *en lien avec la définition*

Si  $X$  est un vecteur aléatoire sur  $(\Omega, \mathcal{T}, \mathbb{P})$ , pour tout ouvert  $A$  de  $\mathbb{R}^n$  :

$$\{\omega \in \Omega, X(\omega) \in A\} = \{X \in A\} \in \mathcal{T}$$

**Définition 2.5** - vecteur aléatoire à densité

$X$  est un vecteur aléatoire définie sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$  s'il existe  $p : F \rightarrow \mathbb{R}_+$  qui vérifie pour tout  $A$  ouvert de  $F$  :

$$\mathbb{P}(\{X \in A\}) = \int_A p(x) \, dx$$

**Remarque 2.6** - à ce propos

Pour  $A = F$ , la probabilité précédemment évoquée vaut :

$$\mathbb{P}(\{X \in F\}) = 1$$

## II Lois usuelles

**Définition 2.7** - loi d'une variable aléatoire

La loi d'une variable aléatoire discrète  $X$  à valeurs dans  $F$  (i.e.  $\mathbb{P}(\{X \in F\}) = 1$ ) est entièrement définie par la famille de réels positifs :

$$\left( \mathbb{P}(\{X = x\}) \right)_{x \in F}$$

de somme 1.

**Exemple 2.8** - loi de Bernoulli

Pour une loi de Bernoulli :

- $F = \{0, 1\}$
- $\mathbb{P}(\{X = 1\}) = p$  et  $\mathbb{P}(\{X = 0\}) = 1 - p$

Une telle variable aléatoire mesure la probabilité de succès d'une épreuve de Bernoulli (succès de probabilité  $p$ , échec de probabilité  $1 - p$ ).

### Exemple 2.9 - loi binomiale

Pour une loi binomiale :

- $F = \llbracket 0, n \rrbracket$  où  $n \in \mathbb{N}^*$
- $\forall k \in \llbracket 0, n \rrbracket, \mathbb{P}(\{X = k\}) = \binom{n}{k} p^k (1-p)^{n-k}$

Une telle variable aléatoire mesure le nombre de succès au terme de la répétition indépendante de  $n$  épreuves de Bernoulli du même paramètre  $p$ .

### Exemple 2.10 - loi géométrique

Pour une loi géométrique :

- $F = \mathbb{N}^*$ .
- $\forall k \in \mathbb{N}^*, \mathbb{P}(\{X = k\}) = p(1-p)^{k-1}$

En numérotant à partir de 1 une suite d'épreuves de Bernoulli répétées indépendamment et indéfiniment, une telle variable aléatoire mesure l'indice du premier succès.

### Exemple 2.11 - loi de Poisson

Pour une loi de Poisson :

- $F = \mathbb{N}$
- $\forall k \in \mathbb{N}, \mathbb{P}(\{X = k\}) = \frac{\lambda^k}{k!} e^{-\lambda}$

Une loi de Poisson a des intérêts multiples, comme celui d'approximer sous certaines conditions une loi binomiale.

### Remarque 2.12 - sur ces lois

On retrouve par dénombrement l'expression de telles lois. Par exemple dans le cas de la loi géométrique,  $\{X = k\}$  correspond à l'évènement "La  $k$ -ème épreuve est la première à réussir.". Cela revient à avoir vu échouer les  $k - 1$  épreuves précédentes :

$$\mathbb{P}(\{X = k\}) = p(1-p)^{k-1}$$

### III Lois marginales

**Proposition 2.13** - *formule des lois marginales*

Soit  $X$  et  $Y$  deux vecteurs aléatoires discrètes sur  $(\Omega, \mathcal{T}, \mathbb{P})$ , respectivement à valeurs dans  $F$  et  $G$ . On a :

$$1. \forall x \in F, \mathbb{P}(\{X = x\}) = \sum_{g \in G} \mathbb{P}(\{Y = g\})$$

$$2. \forall g \in G, \mathbb{P}(\{Y = g\}) = \sum_{x \in F} \mathbb{P}(\{X = x\})$$

**Remarque 2.14** - *démonstration*

On doit ceci à la formule des probabilités totales appliquée aux systèmes complets d'évènements  $(Y = g)_{g \in G}$  et  $(X = x)_{x \in F}$ .

### IV Variables aléatoires à densité

Pour une *variable aléatoire à densité*, on dira que la densité caractérise la loi de cette variable aléatoire :

**Définition 2.15** - *variable aléatoire à densité*

Soit  $X$  est une variable aléatoire sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$ .  $X$  est qualifiée de *variable aléatoire à densité* s'il existe  $p : F \rightarrow [0; 1]$ , dite *densité de probabilité*, vérifiant pour toute partie  $A$  de  $F$  :

$$\mathbb{P}(\{X \in A\}) = \int_A p(t) dt$$

**Remarque 2.16** - *sur cette définition*

La donnée de  $X$  est alors entièrement caractérisée par sa densité de probabilité  $p$ .

**Exemple 2.17** - loi de densité uniforme

Pour une loi uniforme de paramètres  $a < b$  dans  $\mathbb{R}$  :

- $F = [a; b]$
- $\forall x \in [a; b], \mathbb{P}(\{X = x\}) = \frac{\mathbb{1}_{[a; b]}(x)}{b - a}$

La fonction **rand** en C suit une loi uniforme sur  $[0; 1]$ .

**Exemple 2.18** - loi de densité gaussienne

Pour une loi gaussienne de paramètres  $\mu \in \mathbb{R}$  et  $\sigma > 0$  :

- $F = \mathbb{R}$
- $\forall x \in [a; b], p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right)$

**Exemple 2.19** - loi de densité exponentielle

Pour une loi exponentielle de paramètre  $\lambda > 0$  :

- $F = \mathbb{R}$
- $\forall x \in \mathbb{R}, p(x) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x)$

**Proposition 2.20** - formule des lois marginales à densité

Soit  $(X, Y)$  un couple de variables aléatoires à densité sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F \times G$ . On note  $p_{(X,Y)}$  la densité de probabilité du couple  $(X, Y)$ .

Alors  $p_X$  et  $p_Y$  vérifient :

1.  $\forall x \in F, p_X(x) = \int_{\mathbb{R}} p_{(X,Y)}(x, y) \, dy$
2.  $\forall y \in G, p_Y(y) = \int_{\mathbb{R}} p_{(X,Y)}(x, y) \, dx$

### Démonstration

On montre le premier résultat. Montrons que :

$$\forall x \in \mathbb{R}, p_X(x) = \int_{\mathbb{R}} p_{(X,Y)}(x,y) dy$$

Ce qui revient par définition à montrer que :

$$\forall A \subset F, \mathbb{P}(\{X \in A\}) = \int_A \underbrace{\int_{\mathbb{R}} p_{(X,Y)}(x,y) dy}_{:=p_X(x)} dx$$

Soit  $A \subset F$ . On a :

$$\begin{aligned} \mathbb{P}(X \in A) &= \mathbb{P}\left((X,Y) \in A \times G\right) \\ &= \int_{A \times G} p_{(X,Y)}(x,y) d(x,y) \\ &= \int_A \left( \int_G p_{(X,Y)}(x,y) dy \right) dx \end{aligned}$$

D'où le résultat.

## V Espérance d'une variable aléatoire

### V.1 Variable aléatoire discrète

#### Définition 2.21 - famille sommable de réels positifs

On dit qu'une *famille*  $(u_i)_{i \in I}$  de *nombre réels positifs* est *sommable* lorsqu'il existe  $M \geq 0$  tel que, pour toute partie finie  $J \subset I$ , on ait  $\sum_{j \in J} u_j \leq M$ . On définit alors *la somme de la famille* par :

$$\sum_{i \in I} u_i = \sup_{\substack{J \subset I \\ J \text{ finie}}} \sum_{j \in J} u_j$$

**Définition 2.22** - *espérance d'une variable aléatoire discrète*

Soit  $X$  une variable aléatoire discrète à valeurs dans  $F \subset \mathbb{R}$ .  $X$  est dite *sommable* si elle admet un moment d'ordre 1 *i.e.* si la famille  $\left(x\mathbb{P}(\{X = x\})\right)_{x \in F}$  est sommable. On notera alors  $\mathbb{E}(X)$  son espérance définie ainsi :

$$\mathbb{E}(X) = \sum_{x \in F} x\mathbb{P}(\{X = x\})$$

**Exemple 2.23** - *espérance d'une fonction indicatrice*

Si  $A$  est un évènement de  $\Omega$ , alors  $\mathbb{1}_A : \Omega \rightarrow \{0, 1\}$  est une variable aléatoire sommable (car  $\mathbb{1}_A(\Omega)$  est fini). Puis :

$$\mathbb{E}(\mathbb{1}_A) = \mathbb{P}(A)$$

**Théorème 2.24** - *formule de transfert pour une variable aléatoire discrète*

Soit  $X$  une variable aléatoire discrète sommable à valeurs dans  $F \subset \mathbb{R}$  et  $g : F \rightarrow G$ . Alors  $g(X)$  est également une variable aléatoire sommable et :

$$\mathbb{E}(g(X)) = \sum_{x \in F} g(x)\mathbb{P}(\{X = x\})$$

## V.2 variable aléatoire à densité

**Définition 2.25** - *intégrabilité d'une variable aléatoire à densité*

Soit  $X$  une variable aléatoire à densité à valeurs dans  $F$  un espace vectoriel de dimension  $n$ . On dit de  $X$  qu'elle est *intégrable* si l'intégrale :

$$\int_F \|x\| p(x) \, dx$$

converge. Le cas échéant on dit que  $X$  admet une espérance  $\mathbb{E}(X)$  vérifiant :

$$\mathbb{E}(X) = \underbrace{\int_F \underbrace{x}_{\in F} \underbrace{p(x)}_{\in \mathbb{R}_+} \, dx}_{\in F}$$

**Remarque 2.26** - sur cette définition

Il est commun d'avoir  $F = \mathbb{R}$  muni de la valeur absolue classique ou  $F = \mathbb{R}^n$  peu importe la norme (cf. dimension finie).

### V.3 exemples

**Exemple 2.27** - espérance d'une loi de Bernoulli

Si  $X$  suit une loi de Bernoulli de paramètre  $p \in [0; 1]$ , alors  $X(\Omega) = \{0, 1\}$  est fini,  $X$  est donc sommable et :

$$\begin{aligned}\mathbb{E}(X) &= 0 \times (1 - p) + 1 \times p \\ &= p\end{aligned}$$

**Exemple 2.28** - espérance d'une loi binomiale

Si  $X$  suit une loi binomiale de paramètres  $n \in \mathbb{N}^*$  et  $p \in [0; 1]$ , alors  $X(\Omega) = \llbracket 0, n \rrbracket$  est fini,  $X$  est donc sommable et :

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} && \text{premier terme nul} \\ &= \sum_{k=1}^n \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k} \\ &= np \sum_{k=1}^n \frac{(n-1)!}{(k-1)!(n-k)!} p^{k-1} (1-p)^{n-k} \\ &= np \sum_{j=0}^{n-1} \frac{(n-1)!}{j!(n-j-1)!} p^j (1-p)^{n-1-j} && \text{changement d'indice} \\ &= np \left( p + (1-p) \right)^{n-1} && \text{formule du binôme de Newton} \\ &= np\end{aligned}$$

d'où le résultat.



**Exemple 2.29** - *espérance d'une loi de Poisson*

Si  $X$  suit une loi de Poisson de paramètres  $n \in \mathbb{N}^*$  et  $p \in [0; 1]$ , alors  $X(\Omega) = \mathbb{N}$  est dénombrable,  $X$  est donc sommable seulement si la quantité suivante admet une limite finie quand  $N$  tend vers  $+\infty$  :

$$\begin{aligned}\sum_{k=1}^N k \frac{\lambda^k}{k!} e^{-\lambda} &= \sum_{k=1}^N \frac{\lambda^k}{(k-1)!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^N \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \sum_{j=0}^{N-1} \frac{\lambda^j}{j!} \\ &\xrightarrow{N \rightarrow +\infty} \lambda e^{-\lambda} e^{\lambda} = \lambda\end{aligned}$$

$X$  est donc effectivement sommable, et son espérance vaut :

$$\mathbb{E}(X) = \lambda$$

**Exemple 2.30** - *espérance d'une loi géométrique*

Si  $X$  suit une loi de géométrie de paramètre  $p \in ]0; 1[$  (on évite les cas pathologiques), alors  $X(\Omega) = \mathbb{N}$  est dénombrable,  $X$  est donc sommable seulement si la quantité suivante admet une limite finie quand  $N$  tend vers  $+\infty$  :

$$\sum_{k=1}^N kp(1-p)^{k-1} = p \sum_{k=1}^N k(1-p)^{k-1}$$

Ceci implique la dérivée d'une somme géométrique de raison  $(1-p)$ , valant :

$$\sum_{k=0}^{+\infty} (1-p)^k = \frac{1}{1-(1-p)} = \frac{1}{p}$$

Par dérivation terme à terme on a bien sommabilité de  $X$ , et on trouve :

$$\mathbb{E}(X) = p \sum_{k=1}^{+\infty} k(1-p)^{k-1} = p \frac{1}{p^2} = \frac{1}{p}$$

**Exemple 2.31** - *espérance d'une loi à densité exponentielle*

Si  $X$  suit une loi exponentielle de paramètre  $\lambda > 0$ , alors  $X(\Omega) = \mathbb{R}_+$  puis :

$$\begin{aligned} f : \mathbb{R}_+ &\longrightarrow \mathbb{R} \\ x &\longmapsto x\lambda e^{-\lambda x} \end{aligned}$$

est continue par morceaux, avec par croissances comparées :

$$\lim_{x \rightarrow \infty} x^2 f(x) = 0$$

donc :

$$f(x) \underset{x \rightarrow \infty}{=} o\left(\frac{1}{x^2}\right)$$

et  $X$  est intégrable par comparaison avec une fonction de référence. Son espérance vaut alors :

$$\begin{aligned} \mathbb{E}(X) &= \int_0^{+\infty} x\lambda e^{-\lambda x} \, dx \\ &= \left[-xe^{-\lambda x}\right]_0^{+\infty} + \int_0^{+\infty} e^{-\lambda x} \, dx && \text{intégration par parties} \\ &= 0 + \left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^{+\infty} \\ &= \frac{1}{\lambda} \end{aligned}$$

d'où le résultat.

**Exemple 2.32** - *espérance d'une loi à densité gaussienne*

Si  $X$  suit une loi gaussienne de paramètres  $\mu \in \mathbb{R}$  et  $\sigma > 0$ , alors  $X(\Omega) = \mathbb{R}$  puis :

$$f : \mathbb{R} \longrightarrow \mathbb{R}$$
$$x \longmapsto x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

est continue par morceaux, avec par croissances comparées :

$$\lim_{x \rightarrow \infty} x^2 f(x) = 0$$

donc :

$$f(x) \underset{x \rightarrow \infty}{=} o\left(\frac{1}{x^2}\right)$$

et  $X$  est intégrable par comparaison avec une fonction de référence. Son espérance vaut alors :

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{+\infty} x \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx \\ &= \int_{-\infty}^{+\infty} (\sigma t + \mu) \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) \sigma dt \quad \text{changement de variable } t = \frac{x-\mu}{\sigma} \\ &= \int_{-\infty}^{+\infty} t \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt + \mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt \\ &= 0 + \mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt \quad \text{la première intégrale est nulle par imparité} \\ &= \mu \quad \text{la seconde intégrale vaut 1 (on le montre tout de suite après)} \end{aligned}$$

Enfin montrons que  $I = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}t^2\right) dt = 1$ . On a :

$$\begin{aligned} I^2 &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \exp\left(-\frac{1}{2}(x^2 + y^2)\right) dx dy \quad \text{Fubini pour intégrales} \\ &= \frac{1}{2\pi} \int_0^{2\pi} \int_0^{+\infty} r e^{-\frac{1}{2}r^2} dr d\theta \quad \text{changement de variable en coordonnées polaires} \\ &= \frac{1}{2\pi} \times 2\pi \times \left[-e^{-\frac{1}{2}r^2}\right]_0^{+\infty} \\ &= 1 \end{aligned}$$

d'où  $I = 1$  puis  $\mathbb{E}(X) = \mu$ .

**Remarque 2.33** - sur la démonstration précédente

En passant en coordonnées polaires, on a utilisé le fait que :

$$d(x, y) = r dr d\theta$$

Ceci est une application du théorème de changement de variable en dimension quelconque :

$$\int_{\varphi(U)} f(x) dx = \int_U f(\varphi(x)) \left| \det \left( J_{\varphi}(x) \right) \right| dx$$

où ici :

$$\begin{aligned} \varphi : U = \mathbb{R}_+ \times [0; 2\pi[ &\longrightarrow \mathbb{R}^2 \\ (r, \theta) &\longmapsto (r \cos(\theta), r \sin(\theta)) \end{aligned}$$

est un  $\mathcal{C}^1$ -difféomorphisme, de jacobien  $\det \left( J_{\varphi}(r, \theta) \right)$  en  $(r, \theta)$  valant  $r$ , d'où le résultat.

## VI Indépendance de variables aléatoires

**Définition 2.34** - indépendance de variables aléatoires

Soit  $X$  et  $Y$  une famille de variables aléatoires sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$  et  $G$  respectivement. On dit que  $X$  et  $Y$  sont *indépendantes* si pour tous  $x \in F$  et  $y \in G$  :

$$\mathbb{P}(\{(X, Y) = (x, y)\}) = \mathbb{P}(\{X = x\}) \mathbb{P}(\{Y = y\})$$

**Théorème 2.35** - caractérisation de l'indépendance de variables aléatoires

Soit  $X$  et  $Y$  une famille de variables aléatoires sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$  et  $G$  respectivement. Les assertions suivantes sont équivalentes :

1.  $X$  et  $Y$  sont indépendantes.
2. Pour toutes fonctions  $f$  et  $g$  bornées de  $F$  et  $G$  respectivement dans  $\mathbb{R}$  :

$$\mathbb{E}(f(X)g(Y)) = \mathbb{E}(f(X))\mathbb{E}(g(Y))$$

**Remarque 2.36** - sur ce théorème

Ce théorème sert en particulier dans son sens direct.

**Proposition 2.37** - caractérisation de l'indépendance de variables aléatoires à densité

Soit  $X_1, \dots, X_n$  des variables aléatoires de densités respectives  $p_1, \dots, p_n$ . Les  $X_i$  sont mutuellement indépendantes si et seulement si  $(X_1, \dots, X_n)$  est une variable aléatoire à densité de densité de probabilité :

$$p : (x_1, \dots, x_n) \mapsto \prod_{i=1}^n p_i(x_i)$$

## VII Propriétés de l'espérance

**Théorème 2.38** - linéarité de l'espérance

Soit  $X$  et  $Y$  deux variables aléatoires discrètes sommables (resp. intégrables) sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$ . Alors pour tous  $(\alpha, \beta) \in \mathbb{R}^2$ ,  $\alpha X + \beta Y$  est une variable aléatoire discrète sommable (resp. intégrable) et :

$$\mathbb{E}(\alpha X + \beta Y) = \alpha \mathbb{E}(X) + \beta \mathbb{E}(Y)$$

**Théorème 2.39** - croissance de l'espérance

Soit  $X$  et  $Y$  deux variables aléatoires réelles discrètes sommables (resp. intégrables) sur  $(\Omega, \mathcal{T}, \mathbb{P})$ . Si  $X \leq Y$  presque sûrement, alors :

$$\mathbb{E}(X) \leq \mathbb{E}(Y)$$

**Théorème 2.40** - de comparaison d'espérances

Soit  $X$  et  $Y$  deux variables aléatoires sur  $(\Omega, \mathcal{T}, \mathbb{P})$  à valeurs dans  $F$  telles que :

- $Y$  est sommable (resp. intégrable)
- $\|X\|_F \leq \|Y\|_F$  presque sûrement.

Alors  $X$  est sommable.

### VII.1 Des inégalités

**Proposition 2.41** - *inégalité de Markov*

Soit  $X$  une variable aléatoire réelle positive sommable (resp. intégrable) sur  $(\Omega, \mathcal{T}, \mathbb{P})$ . Alors :

$$\forall a > 0, \mathbb{P}(\{X \geq a\}) \leq \frac{\mathbb{E}(X)}{a}$$

**Démonstration**

On a l'inégalité :

$$a\mathbb{1}_{Z \geq a} \leq Z\mathbb{1}_{Z \geq a} \leq Z$$

Par croissance et linéarité de l'espérance :

$$a\mathbb{P}(\{\mathbb{1}_Z\}) \leq \mathbb{E}(Z)$$

Ainsi on a le résultat :

$$\mathbb{P}(Z \geq a) \leq \frac{\mathbb{E}(Z)}{a}$$

**Remarque 2.42** - *importante ici*

Si  $F \neq \mathbb{R}$  il n'y a qu'à considérer la variable aléatoire  $\|X\|_F$ , bien à valeurs dans  $\mathbb{R}_+$  et lui appliquer le résultat. Cette astuce est valable dans tous les énoncés de cette section.

**Proposition 2.43** - *inégalité de Bienaymé-Tchebychev*

Soit  $X$  une variable aléatoire réelle sommable sur  $(\Omega, \mathcal{T}, \mathbb{P})$  admettant une variance finie (ou si  $X^2$  est sommable). Alors :

$$\forall \varepsilon > 0, \mathbb{P}(\{|X - \mathbb{E}(X)| \geq \varepsilon\}) \leq \frac{\mathbb{V}(X)}{\varepsilon^2}$$

**Démonstration**

On applique l'inégalité de Markov à la variable aléatoire  $(X - \mathbb{E}(X))^2$  qui est positive et sommable. On a :

$$\mathbb{P}(\{|X - \mathbb{E}(X)| \geq \varepsilon\}) = \mathbb{P}(\{(X - \mathbb{E}(X))^2 \geq \varepsilon^2\}) \leq \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\varepsilon^2} = \frac{\mathbb{V}(X)}{\varepsilon^2}$$

**Théorème 2.44** - *inégalité de Cauchy-Schwarz*

Soit  $X$  et  $Y$  deux variables aléatoires réelles sommables sur  $(\Omega, \mathcal{T}, \mathbb{P})$  telles que  $X^2$  et  $Y^2$  soient sommables. Alors :

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \mathbb{E}(Y^2)}$$

**Remarque 2.45** - *cas particulier*

En appliquant le théorème pour  $X$  réelle positive quelconque et  $Y = \bar{1}$  :

$$\mathbb{E}(X) \leq \sqrt{\mathbb{E}(X^2)}$$

**Démonstration**

On considère pour tout  $t \in \mathbb{R}$  la variable aléatoire :

$$Z_t = (X + tY)^2 \geq 0$$

qui est sommable par linéarité. Par croissance de l'espérance :

$$0 \leq \mathbb{E}(Z_t) = \mathbb{E}(X^2) + 2t\mathbb{E}(XY) + t^2\mathbb{E}(Y^2)$$

Le polynôme en  $t$  de second degré  $\mathbb{E}(Y^2)t^2 + 2\mathbb{E}(XY)t + \mathbb{E}(X^2)$  est donc à discriminant négatif ou nul :

$$4\mathbb{E}(XY)^2 - 4\mathbb{E}(Y^2)\mathbb{E}(X^2) \leq 0$$

En effet, si le discriminant était strictement positif, le polynôme s'annulerait en deux points distincts, et serait négatif entre ces deux points. Or on a positivité du polynôme pour tout  $t$ .

Le résultat découle de cette dernière égalité :

$$\begin{aligned} \mathbb{E}(XY)^2 &\leq \mathbb{E}(X^2) \mathbb{E}(Y^2) \\ \text{donc } |\mathbb{E}(XY)| &\leq \sqrt{\mathbb{E}(X^2) \mathbb{E}(Y^2)} \end{aligned}$$

**Remarque 2.46** - *condition suffisante pour que  $XY$  soit sommable*

L'inégalité de Cauchy-Schwarz indique clairement que si  $X^2$  et  $Y^2$  sont sommables, alors il en est de même pour  $XY$ . Une autre façon de le démontrer est l'inégalité de Young, qui porte directement sur les variables, et non plus sur les espérances :

$$|XY| \leq \frac{X^2}{2} + \frac{Y^2}{2}$$

Cette dernière inégalité se démontre en sachant que  $(X - Y)^2 \geq 0$ .

## VIII Variance et covariance

### Définition 2.47 - variance d'une variable aléatoire

Soit  $X$  une variable aléatoire réelle sommable sur  $(\Omega, \mathcal{T}, \mathbb{P})$ . On dit que  $X$  admet *une variance* si  $X^2$  est sommable. Dans ce cas on note  $\mathbb{V}(X)$  la variance de  $X$  définie par :

$$\mathbb{V}(X) = \mathbb{E}\left((X - \mathbb{E}(X))^2\right)$$

### Proposition 2.48 - formule de König-Huygens

Soit  $X$  une variable aléatoire réelle sommable sur  $(\Omega, \mathcal{T}, \mathbb{P})$ . Si  $X$  admet une variance, alors :

$$\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

### Démonstration

On développe :

$$\begin{aligned}\mathbb{V}(X) &= \mathbb{E}\left((X - \mathbb{E}(X))^2\right) \\ &= \mathbb{E}(X^2) - 2\mathbb{E}(X)\mathbb{E}(X) + \mathbb{E}(X)^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2\end{aligned}$$

### Définition 2.49 - covariance de deux variables aléatoires

Soit  $X$  et  $Y$  deux variables aléatoires réelles sommables sur  $(\Omega, \mathcal{T}, \mathbb{P})$  telles que  $XY$  est sommable. On appelle *covariance de  $X$  et  $Y$*  la quantité :

$$\text{Cov}(X, Y) = \mathbb{E}\left((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))\right)$$

En développant, on trouve :

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Le résultat est analogue à la formule de König-Huygens.



**Proposition 2.50** - variance de la somme de deux variables aléatoires

Soit  $X$  et  $Y$  deux variables aléatoires réelles sommables sur  $(\Omega, \mathcal{T}, \mathbb{P})$  telles que  $X^2$  et  $Y^2$  sont sommables. On a :

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + \text{Cov}(X, Y)$$

Si  $X$  et  $Y$  sont indépendantes, alors :

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y)$$

**Démonstration**

On a :

$$\begin{aligned}\mathbb{V}(X + Y) &= \mathbb{E}\left((X + Y)^2\right) - \mathbb{E}(X + Y)^2 \\ &= \mathbb{E}(X^2) + 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - \left(\mathbb{E}(X) + \mathbb{E}(Y)\right)^2 \\ &= \mathbb{E}(X^2) + 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - \left(\mathbb{E}(X)^2 + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y)^2\right) \\ &= \underbrace{\mathbb{E}(X^2) - \mathbb{E}(X)^2}_{=\mathbb{V}(X)} + \underbrace{\mathbb{E}(Y^2) - \mathbb{E}(Y)^2}_{=\mathbb{V}(Y)} + 2 \underbrace{\left(\mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)\right)}_{=\text{Cov}(X,Y)}\end{aligned}$$

Puis si  $X$  et  $Y$  sont indépendantes,  $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$  donc  $\text{Cov}(X, Y) = 0$ . D'où les résultats.

## IX Outils pour le calcul de lois de variables aléatoires

### IX.1 fonction génératrice des moments

Inutile mais je pose ça là.

**Définition 2.51** - moment d'une variable aléatoire

Soit  $X$  une variable aléatoire à valeurs dans  $F$  sur  $(\Omega, \mathcal{T}, \mathbb{P})$ . On dit que  $X$  admet un *moment d'ordre  $n$*  si  $\|X^n\|_F$  est sommable. Dans ce cas on note  $\mathbb{E}(X^n)$  le moment d'ordre  $n$  de  $X$ . En particulier :

- être sommable revient à admettre un moment d'ordre 1
- admettre une variance revient à admettre un moment d'ordre 2.

**Définition 2.52** - fonction génératrice pour une VARD

Soit  $X$  une variable aléatoire réelle discrète admettant des moments d'ordre  $n$  pour tout  $n \in \mathbb{N}$ . On appelle *fonction génératrice de  $X$*  la fonction :

$$\begin{aligned} G_X : \mathbb{R} &\longrightarrow \mathbb{R} \\ t &\longmapsto \mathbb{E}(t^X) \end{aligned}$$

Ainsi car  $X$  est discrète :

$$G_X(t) = \sum_{x \in X(\omega)} \mathbb{P}(\{X = x\}) t^x$$

**Exemple 2.53** - fonction génératrice d'une loi de Bernoulli

Si  $X$  suit une loi de Bernoulli de paramètre  $p \in [0; 1]$ , alors :

$$G_X(t) = (1 - p) + pt$$

**Exemple 2.54** - fonction génératrice d'une loi binomiale

Si  $X$  suit une loi binomiale de paramètres  $n \in \mathbb{N}^*$  et  $p \in [0; 1]$ , alors :

$$\begin{aligned} G_X(t) &= \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} t^k \\ &= \sum_{k=0}^n \binom{n}{k} (pt)^k (1-p)^{n-k} \\ &= (1 - p + pt)^n \end{aligned} \quad \text{formule du binôme de Newton}$$

**Proposition 2.55** - fonction génératrice d'une somme de VARD indépendantes

Soit  $X$  et  $Y$  des variables aléatoires réelles discrètes indépendantes de fonctions génératrices  $G_X$  et  $G_Y$  respectivement. Alors la fonction génératrice de  $X + Y$  est :

$$G_{X+Y} = G_X \times G_Y$$

**Exemple 2.56** - loi binomiale

Soit  $X_1, \dots, X_n$  des variables aléatoires indépendantes et identiquement distribuées (IID) suivant une loi de Bernoulli de paramètre  $p \in [0; 1]$ . Alors la fonction génératrice de  $Y = \sum_{i=1}^n X_i$  est :

$$\begin{aligned} G_Y(t) &= \prod_{i=1}^n G_{X_i}(t) && \text{par indépendance} \\ &= \left( (1-p) + pt \right)^n && \text{car les } X_i \text{ suivent une loi de Bernoulli de même paramètre} \end{aligned}$$

On retrouve bien le résultat.

**Exemple 2.57** - fonction génératrice d'une loi de Poisson

Si  $X$  suit une loi de Poisson de paramètre  $\lambda > 0$ , alors :

$$\begin{aligned} G_X(t) &= \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} e^{-\lambda} t^k \\ &= e^{-\lambda} \sum_{k=0}^{+\infty} \frac{(\lambda t)^k}{k!} \\ &= e^{-\lambda} e^{\lambda t} && \text{série exponentielle} \\ &= e^{\lambda(t-1)} \end{aligned}$$

**Exemple 2.58** - fonction génératrice d'une loi géométrique

Si  $X$  suit une loi géométrique de paramètre  $p \in ]0; 1[$ , alors :

$$\begin{aligned} G_X(t) &= \sum_{k=1}^{+\infty} p(1-p)^{k-1} t^k \\ &= pt \sum_{k=0}^{+\infty} \left( (1-p)t \right)^k \\ &= \frac{pt}{1 - (1-p)t} && \text{série géométrique} \end{aligned}$$

On pourra retenir, en notant  $q = 1 - p$  :

$$G_X(t) = \frac{pt}{1 - qt}$$

**Exemple 2.59**

On considère  $(X_i)_{i \in \mathbb{N}^*}$  une suite de variables aléatoires IID suivant une loi de géométrique de paramètre  $p \in [0; 1]$ . On note  $N$  une variable aléatoire indépendante des  $X_i$ , à valeurs dans  $\mathbb{N}$ . On pose alors :

$$S : \omega \mapsto \begin{cases} 0 & \text{si } N(\omega) = 0 \\ \sum_{i=1}^{N(\omega)} X_i(\omega) & \text{sinon} \end{cases}$$

Déterminons la fonction génératrice de  $S$  en fonction de celle de  $N$ . Deux démonstrations sont proposées ici.

### Démonstration

Première démonstration proposée par M. DUFOUR, en manipulant les espérances. Par définition :

$$\begin{aligned}
G_S(t) &= \mathbb{E}(t^S) \\
&= \mathbb{E}(\mathbb{1}_\Omega t^S) \\
&= \mathbb{E}\left(\mathbb{1}_{\bigsqcup_{n=0}^{+\infty} \{N=n\}} t^S\right) && \text{utilisation implicite de la FPT} \\
&= \mathbb{E}\left(\sum_{n=0}^{+\infty} \mathbb{1}_{\{N=n\}} t^S\right) \\
&= \sum_{n=0}^{+\infty} \mathbb{E}(\mathbb{1}_{\{N=n\}} t^S) && \text{linéarité de l'espérance} \\
&= \sum_{n=1}^{+\infty} \mathbb{E}\left(\mathbb{1}_{\{N=n\}} t^{\sum_{i=1}^N X_i}\right) + \mathbb{E}(\mathbb{1}_{\{N=0\}} t^0) && \text{définition de } S \\
&= \sum_{n=1}^{+\infty} \mathbb{E}\left(\mathbb{1}_{\{N=n\}} t^{\sum_{i=1}^n X_i}\right) + \mathbb{E}(\mathbb{1}_{\{N=0\}} t^0) && \text{dans le contexte de la somme, } N = n \\
&= \sum_{n=1}^{+\infty} \mathbb{E}(\mathbb{1}_{\{N=n\}}) \mathbb{E}\left(t^{\sum_{i=1}^n X_i}\right) + \mathbb{E}(\mathbb{1}_{\{N=0\}}) && \text{indépendance de } N \text{ avec les } X_i \\
&= \sum_{n=1}^{+\infty} \mathbb{P}(\{N = n\}) G_{X_1 + \dots + X_n}(t) + \mathbb{P}(\{N = 0\}) && \text{esp. de } \mathbb{1} \text{ et déf. fonction génératrice} \\
&= \sum_{n=1}^{+\infty} \mathbb{P}(\{N = n\}) G_{X_1}(t)^n + \mathbb{P}(\{N = 0\}) && \text{car les } X_i \text{ sont IID} \\
&= \sum_{n=0}^{+\infty} \mathbb{P}(\{N = n\}) G_{X_1}(t)^n && \text{en rajoutant le terme } n = 0 \\
&= G_N(G_{X_1}(t)) && \text{définition de la fonction génératrice}
\end{aligned}$$

## Démonstration

Proposition alternative, en manipulant les probabilités. On a  $S(\Omega) = \mathbb{N}$ . Puis par définition :

$$G_S(t) = \sum_{n=0}^{+\infty} \mathbb{P}(S = n) t^n$$

Pour  $n \in \mathbb{N}$ , calculons donc  $\mathbb{P}(\{S = n\})$ . On a par formule des probabilités totales appliquée au système complet d'évènements  $(\{N = k\})_{k \in \mathbb{N}}$  :

$$\begin{aligned} \mathbb{P}(\{S = n\}) &= \sum_{k=0}^{+\infty} \mathbb{P}(\{S = n\} \cap \{N = k\}) \\ &= \sum_{k=0}^{+\infty} \mathbb{P}\left(\left\{\sum_{i=1}^N X_i = n\right\} \cap \{N = k\}\right) \\ &= \sum_{k=0}^{+\infty} \mathbb{P}\left(\left\{\sum_{i=1}^k X_i = n\right\} \cap \{N = k\}\right) && \text{car dans la probabilité, } N = n \\ &= \sum_{k=0}^{+\infty} \mathbb{P}\left(\left\{\sum_{i=1}^k X_i = n\right\}\right) \mathbb{P}(\{N = k\}) && \text{indépendance de } N \text{ avec les } X_i \end{aligned}$$

Ensuite, écrivons :

$$\begin{aligned} G_S(t) &= \sum_{n=0}^{+\infty} \left( \sum_{k=0}^{+\infty} \mathbb{P}\left(\left\{\sum_{i=1}^k X_i = n\right\}\right) \mathbb{P}(\{N = k\}) \right) t^n \\ &= \sum_{k=0}^{+\infty} \mathbb{P}(\{N = k\}) \sum_{n=0}^{+\infty} \mathbb{P}\left(\left\{\sum_{i=1}^k X_i = n\right\}\right) t^n && \text{théorème de Fubini positif} \\ &= \sum_{k=0}^{+\infty} \mathbb{P}(\{N = k\}) G_{\sum_{i=1}^k X_i}(t) \\ &= \sum_{k=0}^{+\infty} \mathbb{P}(\{N = k\}) \prod_{i=1}^k G_{X_i}(t) && \text{indépendance des } X_i \\ &= \sum_{k=0}^{+\infty} \mathbb{P}(\{N = k\}) G_{X_1}(t)^k && \text{les } X_i \text{ sont identiquement distribuées} \\ &= G_N(G_{X_1}(t)ig) \end{aligned}$$

On retrouve bien le résultat, via un point de vue probabiliste.

## Questions de cours et remarques

### Questions de cours

1. lois discrètes usuelles (de Bernoulli, binomiale, géométrique, de Poisson)
2. lois de densité usuelles
3. inégalité de Markov
4. inégalité de Bienaymé-Tchebychev
5. covariance de la somme de variables aléatoires (et sa démonstration)

### Remarques

- Les énoncés sont à énoncer rigoureusement, en toute connaissance des hypothèses associées.