

# Chapitre 1

## Erreurs d'arrondi

Notes rédigées par Raphaël JONTEF  
Avec l'aide de Github Copilot

Cours enseigné par Marc Durufle

Enseirb-Matmeca  
filière informatique

21 janvier 2026

# Table des matières

|           |                                              |          |
|-----------|----------------------------------------------|----------|
| <b>I</b>  | <b>Représentation des nombres en machine</b> | <b>2</b> |
| I.1       | Entiers . . . . .                            | 2        |
| I.2       | Représentation des réels . . . . .           | 2        |
| <b>II</b> | <b>Erreurs d'arrondi</b>                     | <b>3</b> |
| II.1      | Opérations élémentaires . . . . .            | 3        |
| II.1.1    | Mesure de l'erreur d'arrondi . . . . .       | 3        |
| II.1.2    | Somme de deux réels . . . . .                | 4        |
| II.1.3    | Produit de deux réels . . . . .              | 4        |

# I Représentation des nombres en machine

## I.1 Entiers

Les Entiers sont codés en binaire. On écrit alors pour  $n \in \mathbb{N}$  :

$$n = \sum_{k=0}^{n-1} a_k 2^k$$

où  $a_k \in \{0, 1\}$  est appelé *bit*.

On peut représenter les entiers signés en utilisant le bit de poids fort (le bit le plus à gauche) pour représenter le signe : 0 pour positif, 1 pour négatif.

On peut aussi utiliser la représentation en complément à 2 pour représenter les entiers signés. Dans cette représentation, un entier négatif  $-n$  est représenté par  $2^m - n$  où  $m$  est le nombre de bits utilisés pour représenter l'entier.

Avec une telle implementation, on peut représenter les entiers de  $-2^{m-1}$  à  $2^{m-1} - 1$  et la somme, la différence, le produit, la division de deux entiers est toujours correcte modulo  $2^m$ .

## I.2 Représentation des réels

Pour  $x \in \mathbb{R}^*$ , on écrit :

$$x = y2^e \quad \text{avec} \quad \begin{cases} 1 \leq y < 2 \\ e \in \mathbb{Z} \end{cases}$$

On écrit alors  $y$  en binaire :

$$y = \sum_{k=0}^{+\infty} y_k 2^{-k}$$

où  $y_k \in \{0, 1\}$ .

On appelle *mantisse* la partie  $y$  et *exposant* la partie  $e$ .

En machine, on ne peut pas représenter un réel avec une précision infinie. On choisit donc de ne garder que  $t$  bits pour la mantisse et  $L$  bits pour l'exposant.

On note  $m$  le nombre de bits total :

$$m = 1 + t + L$$

où 1 bit est utilisé pour le signe.

On note  $\mathcal{F}$  l'ensemble des réels représentables en machine avec cette précision. On a alors :

$$\mathcal{F} = \{0\} \cup \left\{ \pm \left( \sum_{k=0}^{t-1} y_k 2^{-k} \right) 2^e \mid a_0 = 1, y_k \in \{0, 1\}, e \in [e_{\min}, e_{\max}] \right\}$$

où  $e_{\min} = 1 - 2^{L-1}$  et  $e_{\max} = 2^{L-1} - 2$ .

**Définition 1.1** - *nombre dénormalisé*

Un nombre est dit dénormalisé lorsque son exposant dans la norme **IEEE754** est nul, et sa mantisse est non nulle. Dans ce cas, la mantisse est codée sans le bit implicite  $a_0$  :  $a_0 = 0$ .

On appelle *overflow* le fait qu'un calcul donne un résultat supérieur à  $e_{max}$ . On appelle *underflow* le fait qu'un calcul donne un résultat inférieur à  $e_{min}$ . Dans ces deux cas, le résultat est arrondi à 0.

**Exemple 1.2** - *double précision en C*

En C, le type `double` utilise 64 bits pour représenter un réel. On a donc :

- 1 bit pour le signe
- 11 bits pour l'exposant
- 52 bits pour la mantisse

La précision est alors de  $2^{-52} \approx 2.22 \times 10^{-16}$  (en simple précision, elle est de  $2^{-23} \approx 1.19 \times 10^{-7}$ ).

**Remarque 1.3** - *le 0*

Pour  $x = 0$ , on prend  $y = 0$  et  $e = e_{min}$ . On a donc une représentation unique du 0 en machine, au signe près.

**Remarque 1.4** - *les non nuls*

Pour  $x \neq 0$ , on a  $y \geq 1$  d'où  $a_0 = 1$ , sauf si on veut représenter des nombres dénormalisés (inférieurs à  $2^{e_{min}} = 2^{-1024}$ )

## II Erreurs d'arrondi

### II.1 Opérations élémentaires

#### II.1.1 Mesure de l'erreur d'arrondi

Pour  $x$  et  $y$  deux réels et  $\star$  une opération élémentaire (addition, soustraction, multiplication, division), Pour mesurer l'erreur du calcul de  $x \star y$ , on note :

$$e_{\star}(x, y) = \frac{|(x + \delta x) \star (y + \delta y) - x \star y|}{|x \star y|}$$

où  $|\delta x| \ll |x|$  et  $|\delta y| \ll |y|$ . On divise par  $|x \star y|$  pour avoir une mesure relative de l'erreur d'arrondi, et non absolue, c'est-à-dire dépendante du résultat de l'opération  $x \star y$ .

### II.1.2 Somme de deux réels

Soient  $x, y \in \mathbb{R}$ .

$$\begin{aligned}
 e_+(x, y) &= \frac{|(x + \delta x) + (y + \delta y) - (x + y)|}{|x + y|} \\
 &= \frac{|\delta x + \delta y|}{|x + y|} \\
 &\leq \frac{|\delta x|}{|x + y|} + \frac{|\delta y|}{|x + y|} \quad (\text{inégalité triangulaire}) \\
 &= \underbrace{\frac{\delta x}{|x|}}_{\text{erreur initiale sur } x} \cdot \underbrace{\frac{|x|}{|x + y|}}_{\text{coefficient amplificateur}} + \underbrace{\frac{\delta y}{|y|}}_{\text{erreur initiale sur } y} \cdot \underbrace{\frac{|y|}{|x + y|}}_{\text{coefficient amplificateur}}
 \end{aligned}$$

**Remarque 1.5** - *coefficients amplificateur*

Les coefficients amplificateurs équilibrent le comportement de chacun des deux termes pour que leur somme ait un sens à la fois pour  $x$  et pour  $y$ .

### II.1.3 Produit de deux réels