

**Définition 5.1** - *apprentissage*

L'*apprentissage* en informatique permet l'approche de différents problèmes :

- la *classification*, par exemple déterminer un objet sur une image, ou un son sur un flux audio ;
- la *régression*, par exemple prévoir la valeur du cours de la bourse.

**Définition 5.2** - *apprentissage supervisé*

L'*apprentissage supervisé* consiste à entraîner un modèle ou un algorithme à l'aide d'un *ensemble d'apprentissage* :

$$S = \{(x_i, y_i), i \in \llbracket 1, n \rrbracket\} \subset X \times Y \quad \text{avec} \quad \begin{cases} X & \text{l'ensemble des } \textit{objets} \text{ manipulés par le modèle ou l'algorithme} \\ Y & \text{l'ensemble des } \textit{classes} \text{ ou } \textit{valeurs} \text{ associées aux objets de } X \end{cases}$$

$(x, y) \in S$  signifie que *l'objet  $x$  est dans la classe  $y$  ou a pour valeur  $y$ .*

On cherche pour un objet inconnu  $x$  à déterminer une classe ou une valeur  $y$  convenable en s'appuyant sur l'ensemble d'apprentissage  $S$ .

**Définition 5.3** - *fonction de prédiction*

À tout modèle ou algorithme d'apprentissage supervisé on peut associer une *fonction*  $f : X \rightarrow Y$  dite de *prédiction* qui à un objet associe la *classe estimée raisonnable par le modèle ou l'algorithme*.

**Définition 5.4** - *fonction de perte*

À tout modèle ou algorithme d'apprentissage supervisé on peut associer une fonction  $L : Y^2 \rightarrow \mathbb{R}_+$  qui à une prédiction associe une *valeur mesurant son inexactitude*. On a :

$$\forall y \in Y, L(y, y) = 0$$

**Définition 5.5** - fonction de risque empirique

Pour tout modèle ou algorithme d'apprentissage supervisé on peut associer à toute fonction  $f$  de prédiction une espérance appelée *risque*  $R$  par :

$$\begin{aligned} R(f) &= \mathbb{E}_{X,Y} \left( L(Y, f(X)) \right) \\ &= \sum_{(x,y) \in X \times Y} L(y, f(x)) \mathbb{P}_{X,Y}(x, y) \end{aligned}$$

En pratique, on n'a jamais accès à  $\mathbb{P}_{X,Y}$ . On définit alors le *risque empirique* comme étant la moyenne des pertes sur l'ensemble d'apprentissage. Lui est calculable :

$$R_{\text{emp}}(f) = \frac{1}{|S|} \sum_{(x,y) \in S} L(y, f(x))$$

Dès lors, un algorithme d'apprentissage supervisé mettra en œuvre des algorithmes d'optimisation afin de trouver une fonction  $f$  qui minimise le risque empirique.

**Implémentation** - algorithme de classification des  $k$  plus proches voisins - classique

- **Entrée :**
  - un ensemble d'apprentissage  $S \subset X \times Y$  indexé sur  $\llbracket 0, n \rrbracket$
  - une distance  $d : X^2 \rightarrow \mathbb{R}_+$
  - un objet  $x$  de classe inconnue
  - $k$  le nombre de voisins à considérer
- **Sortie :** la classe  $y$  du voisin majoritairement présent parmi les  $k$  plus proches de  $x$

```
1 | file = file de priorité max vide
2 | pour tout  $i \in \llbracket 0, n \rrbracket$  :
3 |     si  $|file| < k$  :
4 |         ajouter  $x_i$  à file avec la priorité  $d(x, x_i)$ 
5 |     sinon :
6 |         si  $d(x, x_i) < file[0]$  :
7 |             supprimer le maximum de file
8 |             ajouter  $x_i$  à file avec la priorité  $d(x, x_i)$ 
9 | renvoyer la classe majoritaire parmi les éléments de file
```