

Chapitre 9 : Grammaires non contextuelles

January 26, 2025

1 Grammaire non contextuelle (ou hors-contexte)

1.1 Vocabulaire

Définition 9.1 - *grammaire au sens général, grammaire de type 0*

Une *grammaire* est défini par un quadruplet (Σ, V, P, S) où :

- Σ est un alphabet fini de *symboles terminaux*, dit aussi *alphabet terminal*
- V est un alphabet fini de *symboles non terminaux* (ou *variables*), dit aussi *alphabet non terminal*
- $P \subset (\Sigma \cup V)^* \times (\Sigma \cup V)^*$ est un ensemble de *règles de production*.
Une règle de production $(w_1, w_2) \in P$, notée $w_1 \rightarrow w_2$ est un couple de mots écrits avec des symboles terminaux et non terminaux.
- $S \in V$ est un symbole non terminal avec un statut particulier de *symbole initial* (ou *axiome, variable initiale*)

Une grammaire sans propriété particulière est dite *type 0*.

Remarque 9.2 - *grammaires*

On note usuellement par des majuscules les symboles non terminaux, et en minuscule les terminaux.

Exemple 9.3 - *de grammaire de type 0*

Pour $\Sigma = \{a\}$, $S = S$, $V = \{S, D, F, X, Y, Z\}$ et $P = \{S \rightarrow DXaD, Xa \rightarrow aaX, XF \rightarrow YF, aY \rightarrow Ya, DY \rightarrow DX, XZ \rightarrow Z, aZ \rightarrow Za, DZ \rightarrow \epsilon\}$, $G = (\Sigma, V, P, S)$ est une grammaire de type 0.

Définition 9.4 - *dérivabilité immédiate*

Soit $G = (\Sigma, V, P, S)$ une grammaire. Soit α et β deux mots de $(\Sigma \cup V)^*$. On dit que α *se dérive immédiatement* en β lorsqu'il existe $(\alpha_1, \beta_1) \in P$ tel que :

$$\exists(u, v) \in \left((\Sigma \cup V)^*\right)^2, \begin{cases} \alpha = u\alpha_1v \\ \beta = u\beta_1v \end{cases}$$

Le cas échéant, on note $\alpha \Rightarrow \beta$. On parle de *dérivation immédiate*. Moralement, la règle de production (α_1, β_1) remplace le facteur α_1 par le facteur β_1 .

Définition 9.5 - *clôture réflexive et transitive*

On note \Rightarrow^* la *clôture réflexive et transitive* de la relation \Rightarrow de dérivabilité immédiate.

\Rightarrow^* est définie comme la plus petite relation au sens de l'inclusion tel que :

- $\forall \alpha \in (\Sigma \cup V)^*, \alpha \Rightarrow^* \alpha$
- $\forall (\alpha, \beta) \in \left((\Sigma \cup V)^*\right)^2, (\alpha \Rightarrow \beta) \implies (\alpha \Rightarrow^* \beta)$
- $\forall (\alpha, \beta, \gamma) \in \left((\Sigma \cup V)^*\right)^3, (\alpha \Rightarrow^* \beta \text{ et } \beta \Rightarrow^* \gamma) \implies (\alpha \Rightarrow^* \gamma)$

Autrement dit, $\alpha \Rightarrow^* \beta$ lorsqu'il existe $(\alpha = \alpha_0, \dots, \alpha_k = \beta)$ une suite de mots dans $(\Sigma \cup V)^*$ telle que :

$$\forall i \in \llbracket 0, k-1 \rrbracket, \alpha_i \Rightarrow \alpha_{i+1}$$

Définition 9.6 - *clôture réflexive et transitive de \Rightarrow*

Soit $G = (\Sigma, V, P, S)$ une grammaire. Soit α et β deux mots de $(\Sigma \cup V)^*$. On note \Rightarrow^* la *clôture réflexive et transitive de la relation \Rightarrow* . Ainsi $\alpha \Rightarrow^* \beta$ lorsqu'il existe $(\alpha = \alpha_0, \dots, \alpha_k = \beta)$ une suite de mots dans $(\Sigma \cup V)^*$ telle que :

$$\forall i \in \llbracket 0, k-1 \rrbracket, \alpha_i \Rightarrow \alpha_{i+1}$$

Exemple 9.7 - de dérivation

Dans la grammaire précédemment introduite :

Pour $\Sigma = \{a\}$ et $V = \{S, D, F, X, Y, Z\}$ et $P = \{S \rightarrow DXaD, Xa \rightarrow aaX, XF \rightarrow YF, aY \rightarrow Ya, DY \rightarrow DX, XZ \rightarrow Z, aZ \rightarrow Za, DZ \rightarrow \epsilon\}$, $G = (\Sigma, V, P, S)$ est une grammaire de type 0.

$$\begin{aligned} S &\Rightarrow DXaF \\ &\Rightarrow DaaXF \\ &\Rightarrow DaaYF \\ &\Rightarrow DaYaF \\ &\Rightarrow DYaaF \\ &\Rightarrow DXaaF \\ &\Rightarrow DaaXaF \\ &\Rightarrow DaaaaXF \\ &\Rightarrow DaaaaZ \\ &\Rightarrow DaaaZa \\ &\Rightarrow DaaZaa \\ &\Rightarrow DaZaaa \\ &\Rightarrow DZaaaa \\ &\Rightarrow aaaa \end{aligned}$$

D'où $S \Rightarrow^* aaaa$

Définition 9.8 - langage engendré, langage élargi engendré par une grammaire depuis un mot

Soit $G = (\Sigma, V, P, S)$ une grammaire et $\alpha \in (\Sigma \cup V)^*$.

- le *langage engendré par G depuis α* est l'ensemble des mots de Σ^* que l'on peut obtenir par dérivation de α en utilisant les règles de production de G :

$$\mathcal{L}_G(\alpha) = \{\beta \in \Sigma^*, \alpha \Rightarrow^* \beta\}$$

- le *langage élargi engendré par G depuis α* est l'ensemble des mots de $(\Sigma \cup V)^*$ que l'on peut obtenir par dérivation de α en utilisant les règles de production de G :

$$\widehat{\mathcal{L}_G(\alpha)} = \{\beta \in (\Sigma \cup V)^*, \alpha \Rightarrow^* \beta\}$$

Définition 9.9 - *langage engendré par une grammaire*

Soit $G = (\Sigma, V, P, S)$ une grammaire et $\alpha \in (\Sigma \cup V)^*$. Le *langage engendré par G* désigne $\mathcal{L}_G(S)$ le langage engendré par G depuis son symbole initial S .

Exemple 9.10

Pour la grammaire de l'exemple, on pourrait montrer que $\mathcal{L}_G(S) = \{a^{2^n}, n \in \mathbb{N}^*\}$. On montre que ce langage n'est pas régulier (absurde + lemme de l'étoile tmtc)

Définition 9.11 - *langage de type 0*

On dit qu'un *langage est de type 0* s'il peut être engendré par une grammaire de type 0.

Théorème 9.12 - *de Chomsky (HP)*

Les langages de type 0 sont exactement les langages récursivement énumérables, c'est-à-dire les langages reconnaissables par une machine de Turing.

Définition 9.13 - *grammaire contextuelle (HP)*

Une grammaire $G = (\Sigma, V, P, S)$ de type 0 est appelée *grammaire contextuelle (ou de type 1 ou monotone)* lorsque :

$$\forall (\alpha, \beta) \in P \setminus \{(S, \epsilon)\}, |\alpha| \leq |\beta|$$

Moralement, tous les facteurs "produits" sont plus long que les facteurs remplacés.

Exemple 9.14 - *de grammaire qui n'est pas "contextuelle"*

la grammaire exemple définie par $\Sigma = \{a\}$ et $V = \{S, D, F, X, Y, Z\}$ et $P = \{S \rightarrow DXaD, Xa \rightarrow aaX, XF \rightarrow YF, aY \rightarrow Ya, DY \rightarrow DX, XZ \rightarrow Z, aZ \rightarrow Za, DZ \rightarrow \epsilon\}$ puis $G = (\Sigma, V, P, S)$ n'est pas contextuelle :

$$(DZ \rightarrow \epsilon) \in P$$

mais :

$$|DZ| = 2 > |\epsilon| = 0$$

Remarque 9.15 - *indépendance des caractères "contextuel" et "non contextuel"*

Nous le reverrons, mais une grammaire est "contextuelle" indépendamment de son caractère "non contextuel".

Remarque 9.16

Sans l'autorisation d'avoir $(S, \epsilon) \in P$, les langages engendrés par des grammaires contextuelles ne peuvent pas contenir ϵ .

En effet, on a initialement S de longueur 1 et les règles de productions ne peuvent qu'augmenter la longueur du mot. 0 serait donc une longueur inexistente.

Définition 9.17 - *grammaire non contextuelle*

Une grammaire $G = (\Sigma, V, P, S)$ est dite *non contextuelle* (ou *hors contexte* ou encore *algébrique* ou *de type 2*) lorsque :

$$P \subset V \times (\Sigma \cup V)^*$$

Moralement, les règles de production ne permettent de remplacer que des symboles non terminaux (et pas des mots) : des majuscules.

Exemple 9.18 - *de règle de production non valide pour une grammaire "non contextuelle"*

$DZ \rightarrow \epsilon$ n'est pas une règle possible pour une grammaire hors contexte.

Exemple 9.19 - *de grammaire "non contextuelle"*

$G_1 = (\Sigma_1, V_1, P_1, S_1)$ définie par :

- $\Sigma_1 = \{a, b\}$
- $V_1 = \{S_1\}$
- $P_1 = \{S_1 \rightarrow aS_1b, S_1 \rightarrow \epsilon\}$

est une grammaire hors contexte.

Remarque 9.20

On dit "hors contexte" car les symboles non terminaux

PASSE 1 ajouter à l'exemple :

$\widehat{\mathcal{L}_{G_1}(S_1)} = \{a^n S_1 b^n, n \in \mathbb{N}\} \cup \{a^n b^n, n \in \mathbb{N}\}$ pour comprendre le chapeau.

Voir démo 1

Exemple 9.21 - *Langage de Dyck*

Le langage de Dyck (bon parenthésage) est engendré par :

- $\Sigma = \{ (,) \}$
- $S \rightarrow (S)S$
- $S \rightarrow \epsilon$

Remarque 9.22 - *grammaires "non contextuelles" uniquement définies par les règles de production*

En général, on donne une grammaire hors-contexte uniquement avec les règles de production.

On ne précise le symbole initial que si ce n'est pas S .

Les symboles non terminaux sont exactement ceux que l'on rencontre à gauche des règles et les terminaux sont les autres qu'on rencontre.

Remarque 9.23 - *"hors-contexte" \nRightarrow "régulier"*

Les exemples montrent qu'il existe des langages hors contexte qui ne sont pas réguliers.

Remarque 9.24 - *abréviation d'une famille de règles de production*

Pour noter rapidement un ensemble de règles de production utilisant le même symbole non terminal comme départ :

$$\{X, \alpha_1 \rightarrow \dots, X \rightarrow \alpha_k\} \subset P$$

avec $X \in V$, on note :

$$X \rightarrow \alpha_1 | \dots | \alpha_k$$

Ce n'est qu'une notation, on a bien k règles de production derrière ça.

Exemple 9.25 - *exploitant ce raccourci*

G_1 s'écrit :

$$S_1 \rightarrow aS_1b | \epsilon$$

1.2 Langages réguliers et langages hors-contexte

Un résultat à connaître et savoir redémontrer.

Proposition 9.26 - "régulier" \implies "hors-contexte"

Soit Σ un alphabet, Tout langage sur Σ régulier est "hors-contexte".

Voir Démo 2 (elle est incomplète)

Remarque 9.27 - concernant ce résultat

L'inclusion réciproque est fausse si $|\Sigma| \geq 2$:

$$\{a^n b^n, n \in \mathbb{N}\}$$

est un langage hors-contexte mais non régulier.

cette définition sera rappelée, mais il faut vite la comprendre ! FC où on donne la déf, et on doit interpréter !

Définition 9.28 - grammaire linéaire (HP)

$G = (\Sigma, V, P, S)$ est dite :

- *linéaire* si :

$$P \subset V \times (\Sigma^* \cup \Sigma^* V \Sigma^*)$$

Moralement, on a toujours au plus un symbole non terminal (voir Fig.1)

- *linéaire gauche* lorsque :

$$P \subset V \times \left(\Sigma^* \cup (V \Sigma^*) \right)$$

Le facteur "produit" commence par un unique symbole non terminal ou n'en a aucun.

- *linéaire droit* lorsque :

$$P \subset V \times \left(\Sigma^* \cup (\Sigma^* V) \right)$$

Remarque 9.29 - chaîne d'implications

linéaire droit implique linéaire implique hors contexte linéaire gauche implique linéaire implique hors contexte.

Définition 9.30 - langages linéaire, linéaire droit, linéaire gauche

Un langage est dit linéaire (resp. simple, droit, gauche) lorsqu'il peut être engendré par une grammaire linéaire (resp. simple, linéaire droite).

Remarque 9.31 - *existence langages linéaires non réguliers*

$$S \rightarrow aSb \mid \epsilon$$

est linéaire et engendre $\{a^n b^n, n \in \mathbb{N}\}$

Proposition 9.32 - *pour un langage, régulier \iff linéaire droit \iff linéaire gauche*

Soit L un langage. Les propriétés suivantes sont équivalentes.

1. L est régulier
2. L est linéaire droit
3. L est linéaire gauche

Remarque 9.33 - *sur la démo*

En montrant régulier implique linéaire droit, on montre à nouveau que régulier implique hors contexte, ceci constitue une autre démo que la propriété précédente.

Démo 3.